



PATH IA FOR DEVS & TECH

2026

a evolução dos agentes  
**do prompt ao harness.**

# a linha do **tempo**

três estágios, um gargalo cada: o texto que escrevemos, o contexto que damos ao modelo e o ambiente onde ele executa.

## A EVOLUÇÃO

- 2022 · prompts
- 2024 · contexto
- 2025 · harness
- few-shot, CoT, roles
- RAG, memória, tools
- frameworks, fallback



# context **engineering**

De 2023 a 2025, a pergunta virou 'o que entra na janela?'. RAG, memória e tool use passaram a valer mais que o prompt perfeito.

## O GARGALO

Contexto morria na sessão: trabalho real exige execução longa, paralela e auditável.

**o gargalo migrou para a infra ao  
redor do modelo**



# harness **engineering**

Em 2025+, o diferencial é o ambiente ao redor do modelo:  
permissões, ferramentas, orquestração e resiliência de inferência.

## É ONDE ESTAMOS

O harness é a camada que transforma modelo em engenheiro de verdade.

**nossos conteúdos operam  
exatamente nesta camada**



A grayscale photograph of a man with a beard, wearing a dark t-shirt, sitting at a desk and typing on a laptop. His hands are positioned on the keyboard. In the foreground, there are some papers and a keyboard. The background is slightly blurred, showing a desk with a monitor and some office equipment. The text "modelos de fronteira" is overlaid on the image in a white, sans-serif font. The word "de" is bolded.

modelos **de fronteira**

# o que é **fronteira**?

Fronteira é o pelotão dos modelos mais avançados, dos grandes labs: Anthropic, OpenAI, Google, Z.ai, Alibaba e Moonshot.

## E OS OUTROS?

Não-fronteira: abertos e locais (GPT-OSS, Qwen, Ollama) são a rede de segurança, não o motor.

**na prática: fronteira no topo da cascata, abertos no piso**



# a fronteira **2026**

seis fornecedores no topo, capacidades equivalentes na prática,  
e a liderança trocando de mãos a cada trimestre.

## NO TOPO HOJE

- claude · anthropic
- gpt · openai
- gemini · google
- glm · z.ai
- qwen · alibaba
- kimi · moonshot



# swe-bench **verified**


Claude lidera, mas o pelotão a ~80% é global: Google, DeepSeek, Alibaba e Moonshot empatados dentro de 0,4 ponto.

## SET/2026

95% no topo, 80,2 a 80,6% no pelotão: a diferença real está no caso de uso.

fonte: [lm-stats.com](https://lm-stats.com) • [swebench.com](https://swebench.com)

*O SWE-bench Verified é um benchmark de programação que avalia modelos de IA na resolução de problemas reais do GitHub, provenientes de repositórios Python de código aberto populares. O modelo deve ler o problema, compreender a base de código e gerar um patch funcional. Ele é o padrão-ouro para a avaliação de agentes de IA voltados à programação.*



| Official Leaderboards                                                                                               |                          |                         |                 |      |            |
|---------------------------------------------------------------------------------------------------------------------|--------------------------|-------------------------|-----------------|------|------------|
| Verified                                                                                                            |                          |                         |                 |      |            |
| Verified is a human-filtered subset of 500 instances (total). Defaults to best-only setting (run with --best-only). |                          |                         |                 |      |            |
| [+] Compare results [x] Open Only                                                                                   |                          |                         |                 |      |            |
| #                                                                                                                   | Model                    | Agent                   | % Correct (N=5) | Meta | Score      |
| 1                                                                                                                   | Claude 4.5-Open          | Google Foundation Agent | 79.20           |      | 2025-12-05 |
| 2                                                                                                                   | Claude 4.5-Open (medium) | Exa-ONE-agent           | 79.20           |      | 2025-12-10 |
| 3                                                                                                                   | Deepseek-Secret-Code     | Thal                    | 79.00           |      | 2025-09-28 |
| 4                                                                                                                   | Gemini 3 Pro Preview     | Exa-ONE-agent           | 77.40           |      | 2025-11-20 |
| 5                                                                                                                   | Claude 4 Sonnet          | OPINAI-MONAI-CodeGPT... | 76.80           |      | 2025-09-04 |
| 6                                                                                                                   | MultiByte                | Alibaba-Beta-Dev        | 76.80           |      | 2025-09-01 |
| 7                                                                                                                   | Claude 4.5-Open (short)  | Exa-ONE-agent           | 76.80           |      | 2025-02-17 |
| 8                                                                                                                   | MultiByte                | ACoder                  | 76.80           |      | 2025-09-19 |
| 9                                                                                                                   | Gemini 3 Flash (high)    | Exa-ONE-agent           | 76.80           |      | 2025-02-17 |
| 10                                                                                                                  | MiniMax M2.5 (high)      | Exa-ONE-agent           | 76.80           |      | 2025-02-17 |
| 11                                                                                                                  | MultiByte                | Way                     | 76.80           |      | 2025-09-01 |

# artificial **analysis**


## Score by Benchmark

Average pass@1 on each component benchmark - Higher is better

13 of 13 models

DeepSWE v1.1 Terminal-Bench 4.0 SWE-Atlas-QnA

Artificial Analysis



Component Benchmark Scores

This chart breaks the Artificial Analysis Coding Agent Index into its component benchmarks: DeepSWE v1.1, Terminal-Bench 4.0, and SWE-Atlas-QnA.

What the Score Captures

All current component benchmarks use binary pass/fail outcomes.

# artificial **analysis**

## Cost per Task

Average pay-per-token API cost per task (USD) - Lower is better




fonte: [artificialanalysis.ai](https://artificialanalysis.ai)

# artificial **analysis**

## Artificial Analysis Coding Agent Index vs. Cost per Task

Artificial Analysis Coding Agent Index vs. average pay-per-token API cost per task (USD)




# artificial **analysis**

## Artificial Analysis Coding Agent Index


Artificial Analysis Coding Agent Index v1.5 incorporates 3 benchmarks: DeepSWE v1.1, Terminal-Bench 4.0, and SWE-Atlas-QnA - Higher is better

Artificial Analysis



fonte: [artificialanalysis.ai](https://artificialanalysis.ai)

# llm-stats



fonte: [llm-stats.com](https://llm-stats.com) (Best AI for Coding in 2026)

Comparação das melhores IAs para programação, classificadas com base em resultados de arenas em tempo real e desempenho em benchmarks que abrangem geração de código, depuração e engenharia de software.

# llm-stats

| All Leaderboards                                                                                      |                     |               |               |            |            |             |                   |           |             |  |
|-------------------------------------------------------------------------------------------------------|---------------------|---------------|---------------|------------|------------|-------------|-------------------|-----------|-------------|--|
| LLM Leaderboard                                                                                       |                     |               |               |            |            |             |                   |           |             |  |
| Open LLM Leaderboard                                                                                  |                     |               |               |            |            |             |                   |           |             |  |
| Coding Writing Math Reasoning Long Context Tool Calling Research Agents Image Gen Video Creation More |                     |               |               |            |            |             |                   |           |             |  |
| #                                                                                                     | Model (L)           | LLM State (L) | Reasoning (L) | Coding (L) | Agents (L) | Context (L) | Price \$/M (L)    | Speed (L) | License (L) |  |
| 1                                                                                                     | GPT-4o              | 85.8          | 87.8          | 48.8       | 46.4       | 1.1M        | \$19.08 / \$50.00 | 18tok/s   | 🔒           |  |
| 2                                                                                                     | Claude 3.5          | 85.8          | 83.8          | 55.5       | 41.8       | 1M          | \$19.08 / \$50.00 | 1tok/s    | 🔒           |  |
| 3                                                                                                     | GPT-4o-mini         | 85.8          | 84.1          | 48.0       | 41.5       | 1.1M        | \$5.00 / \$10.00  | 22tok/s   | 🔒           |  |
| 4                                                                                                     | Claude 3.5 Sonnet   | 81.8          | 85.8          | 44.8       | 36.5       | -           | -                 | -         | 🔒           |  |
| 5                                                                                                     | Claude 3.5 Haiku    | 84.8          | 83.8          | 41.0       | 40.8       | 1M          | \$5.00 / \$10.00  | 8tok/s    | 🔒           |  |
| 6                                                                                                     | Mistral 7B          | 84.4          | 81.8          | 41.7       | 40.4       | 1.0M        | \$0.18 / \$0.30   | 8tok/s    | 🔒           |  |
| 7                                                                                                     | Claude 3.5 Opus     | 84.3          | 81.8          | 45.7       | 40.5       | 1M          | \$19.08 / \$50.00 | 8tok/s    | 🔒           |  |
| 8                                                                                                     | Kimi K1             | 83.1          | 81.8          | 43.3       | 39.8       | 1.0M        | \$2.88 / \$14.28  | 8tok/s    | 🔒           |  |
| 9                                                                                                     | GLM-4.5             | 82.8          | 81.8          | 42.8       | 39.8       | 1.0M        | \$1.25 / \$4.00   | 48tok/s   | 🔒           |  |
| 10                                                                                                    | DeepSeek-V3         | 82.1          | 80.1          | 42.7       | 37.8       | 1.0M        | \$0.43 / \$0.87   | 3tok/s    | 🔒           |  |
| 11                                                                                                    | Qwen3.5             | 81.8          | 80.8          | 38.6       | 37.7       | 1.0M        | \$1.05 / \$4.00   | 22tok/s   | 🔒           |  |
| 12                                                                                                    | DeepSeek-V3.1       | 81.8          | 80.8          | 44.4       | 41.3       | 1.0M        | \$0.22 / \$0.66   | -         | 🔒           |  |
| 13                                                                                                    | Hyd preview         | 81.8          | 80.7          | 38.9       | 36.8       | -           | -                 | -         | 🔒           |  |
| 14                                                                                                    | Claude 3.5 Opus 4.8 | 80.8          | 80.3          | 41.7       | 36.5       | 1M          | \$5.00 / \$10.00  | 36tok/s   | 🔒           |  |
| 15                                                                                                    | GPT-4o-mini         | 80.8          | 80.2          | 42.2       | 36.2       | 1.1M        | \$2.00 / \$10.00  | 88tok/s   | 🔒           |  |
| 16                                                                                                    | Gemini 1.5 Flash    | 80.8          | 80.2          | 38.5       | 35.8       | 1.0M        | \$0.75 / \$0.75   | 53tok/s   | 🔒           |  |
| 17                                                                                                    | GLM-4.5 Flash       | 80.3          | 80.2          | 34.6       | 37.2       | 1.0M        | \$0.18 / \$0.30   | 10tok/s   | 🔒           |  |
| 18                                                                                                    | Mistral 7B          | 49.8          | 80.8          | 54.7       | 34.7       | 1.0M        | \$1.25 / \$4.00   | 8tok/s    | 🔒           |  |
| 19                                                                                                    | Qwen3.5 Flash-V2    | 49.1          | 80.8          | 38.1       | 35.1       | -           | -                 | -         | 🔒           |  |
| 20                                                                                                    | Qwen3.5 Flash       | 49.1          | 80.8          | 38.0       | 35.1       | 1M          | \$0.15 / \$0.47   | 10tok/s   | 🔒           |  |
| 21                                                                                                    | Gemini 1.5 Flash    | 48.7          | 80.8          | 38.3       | 33.8       | 1.0M        | \$0.75 / \$0.75   | 51tok/s   | 🔒           |  |
| 22                                                                                                    | Claude 3.5 Sonnet   | 48.3          | 47.2          | 36.9       | 31.7       | 1M          | \$2.00 / \$10.00  | -         | 🔒           |  |

Fonte: [llm-stats.com](https://llm-stats.com) (LLM Leaderboard 2026 - GERAL)



| AI Leaderboards      |                          |           |           |        |        |         |                   |        |         |  |
|----------------------|--------------------------|-----------|-----------|--------|--------|---------|-------------------|--------|---------|--|
| LLM Leaderboard      |                          |           |           |        |        |         |                   |        |         |  |
| Open LLM Leaderboard |                          |           |           |        |        |         |                   |        |         |  |
| Coding               |                          |           |           |        |        |         |                   |        |         |  |
| Writing              |                          |           |           |        |        |         |                   |        |         |  |
| Math                 |                          |           |           |        |        |         |                   |        |         |  |
| Research             |                          |           |           |        |        |         |                   |        |         |  |
| Long Context         |                          |           |           |        |        |         |                   |        |         |  |
| Tool-Coding          |                          |           |           |        |        |         |                   |        |         |  |
| Reasoning            |                          |           |           |        |        |         |                   |        |         |  |
| Image Gen            |                          |           |           |        |        |         |                   |        |         |  |
| Video Creation       |                          |           |           |        |        |         |                   |        |         |  |
| More                 |                          |           |           |        |        |         |                   |        |         |  |
| #                    | Model                    | LLM Stats | Reasoning | Coding | Agents | Context | Price             | Speed  | License |  |
| 1                    | GPT-4o Audio             | 98.9      | 97.9      | 98.5   | 98.4   | 1.9M    | \$10.00 / \$10.00 | 18 min |         |  |
| 2                    | GPT-4o Mini              | 85.0      | 84.1      | 85.8   | 81.8   | 1.9M    | \$5.00 / \$10.00  | 22 min |         |  |
| 3                    | Claude 3.5 Sonnet        | 84.3      | 81.8      | 85.7   | 80.5   | 1M      | \$10.00 / \$10.00 | 2 min  |         |  |
| 4                    | Claude 3.5 Haiku Preview | 84.9      | 86.8      | 81.8   | 78.9   | -       | -                 | -      |         |  |
| 5                    | DeepSeek-V3.1-Flash      | 81.8      | 88.9      | 84.4   | 81.3   | 1.8M    | \$6.25 / \$1.00   | -      |         |  |
| 6                    | Kimi K2                  | 83.1      | 81.8      | 83.3   | 78.8   | 1.8M    | \$2.86 / \$14.29  | 8 min  |         |  |
| 7                    | GLM-4.5                  | 82.8      | 81.0      | 82.8   | 78.8   | 1.8M    | \$1.26 / \$4.00   | 48 min |         |  |
| 8                    | GPT-4o Mini              | 80.8      | 88.2      | 82.2   | 78.2   | 1.9M    | \$3.00 / \$12.00  | 98 min |         |  |
| 9                    | Claude 3.5 Opus          | 84.8      | 83.0      | 81.8   | 80.8   | 1M      | \$5.00 / \$25.00  | 8 min  |         |  |
| 10                   | Claude 3.5 Haiku         | 80.9      | 88.2      | 81.7   | 78.5   | 1M      | \$5.00 / \$25.00  | 58 min |         |  |
| 11                   | Mistral 7B               | 84.4      | 81.8      | 81.7   | 80.4   | 1.8M    | \$8.16 / \$2.70   | 8 min  |         |  |
| 12                   | DeepSeek-V3-Pro-0813     | 82.1      | 88.1      | 80.7   | 77.9   | 1.8M    | \$6.45 / \$8.87   | 3 min  |         |  |
| 13                   | Hydrex                   | 81.0      | 88.7      | 78.8   | 78.8   | -       | -                 | -      |         |  |
| 14                   | Qwen2.5 Max              | 81.0      | 88.0      | 78.8   | 77.7   | 1.8M    | \$1.95 / \$4.95   | 22 min |         |  |
| 15                   | Gemini 1.5 Flash         | 80.8      | 88.9      | 78.8   | 78.8   | 1.8M    | \$0.75 / \$2.75   | 52 min |         |  |
| 16                   | GPT-4o                   | 88.2      | 87.5      | 88.5   | 82.8   | 1.9M    | \$5.00 / \$10.00  | -      |         |  |
| 17                   | Claude 3.5 Haiku         | 85.2      | 86.4      | 82.8   | 81.8   | -       | -                 | -      |         |  |
| 18                   | Orion 4.0                | 86.6      | 88.4      | 87.4   | 87.2   | 500k    | \$2.90 / \$1.00   | 13 min |         |  |
| 19                   | Claude 3.5 Sonnet        | 88.3      | 87.7      | 86.9   | 81.7   | 1M      | \$2.00 / \$18.00  | -      |         |  |
| 20                   | Claude 3.5 Opus          | 84.1      | 88.7      | 78.8   | 81.4   | 1M      | \$5.00 / \$25.00  | -      |         |  |
| 21                   | GPT-4o Mini              | 85.1      | 84.0      | 86.3   | 81.7   | 1.9M    | \$6.20 / \$1.20   | 48 min |         |  |
| 22                   | Qwen2.5 Max              | 89.8      | 88.1      | 86.2   | 79.3   | 1M      | \$1.26 / \$2.75   | -      |         |  |

fonte: [llm-stats.com](https://llm-stats.com) (LLM Leaderboard 2026 - CODING)

# open-router

| GPT4o Latest           | Claude 3.5                                             | Gemini 1.5 Flash       | Kimi K2.5            |
|------------------------|--------------------------------------------------------|------------------------|----------------------|
| Azure                  | Anthropic                                              | Google AI Studio       | Sail Research        |
| Pricing                |                                                        | Pricing                |                      |
| Output                 | \$50 / M tokens                                        | Output                 | \$3.75 / M tokens    |
| Cached Input           | \$1 / M tokens                                         | Cached Input           | \$0.075 / M tokens   |
| Weighted Average Input | —                                                      | Weighted Average Input | \$0.2821 / M tokens  |
| Cache Write            | from \$12.50 / M tokens<br><272K \$12.50<br>>272K \$25 | Cache Write            | \$0.04167 / M tokens |
| Web Search             | \$10 / 1K calls                                        | Web Search             | \$14 / 1K calls      |
| Cache Write (1h)       | —                                                      | Cache Write (1h)       | —                    |
| Image Input            | —                                                      | Image Input            | \$0.75 / M tokens    |
| Input Audio            | —                                                      | Input Audio            | \$0.75 / M tokens    |
| Input Audio Cache      | —                                                      | Input Audio Cache      | \$0.075 / M tokens   |
| Performance            |                                                        | Performance            |                      |
| Latency (p50)          | 11.00 s                                                | Latency (p50)          | 2.15 s               |
| Throughput (p50)       | 22.0 tok/s                                             | Throughput (p50)       | 117.0 tok/s          |


# arenas & **design**

Em tarefas abertas a história se repete: Kimi K3 lidera o Design Arena com 1357 ELO, à frente de Claude Fable 5.1 com 1323.

## DESIGN ARENA - ELO

Em design e texto criativo, todos os de fronteira entregam nível profissional.

fonte: [arena.ai](https://arena.ai) · [designarena.ai](https://designarena.ai)




# custo por **token**

Inferência de ponta custa caro por token. Ou nada, dependendo da arquitetura. As referências dos nossos conteúdos:

## TETO US\$ / 1M TOKENS

Claude US\$ 3 a 15, DeepSeek US\$ 0,14 a 2,19, ClaudeGravity US\$ 0 (cota AI Pro).

fonte: comparativo no nosso conteúdo [claudegravity](#)



use sempre o melhor.

**o melhor virou um pelotão.**

A grayscale photograph of a man with a beard, wearing a dark t-shirt, sitting at a desk and typing on a laptop. The scene is dimly lit, with a computer monitor visible in the background. The text 'conteúdos & pocs' is overlaid on the image in a white, sans-serif font. The ampersand and 'pocs' are highlighted in a light purple color.

conteúdos & pocs

# antigravity **irrestrito**

Parametrizamos o motor de permissões do Agent 2.0 (deny > ask > allow) com 6 wildcards: IDE, CLI e projetos, nos 3 sistemas.

## NOSSO CONTEÚDO

Zero diálogos de confirmação: agentes com autonomia de execução total.

conteúdo completo:

[github.com/pathbit/pathbit-ai-for-devs](https://github.com/pathbit/pathbit-ai-for-devs)

GOOGLE ANTIGRAVITY - ARQUITETURA AGENT 2.0

### Precedência de Permissões e Execução Autônoma



# poc 1 · **antigravity**

Vamos destravar o Agent 2.0 ao vivo e rodar uma tarefa completa sem nenhuma confirmação manual.

## O QUE VAMOS FAZER

Autonomia real com reversão segura: backup automático antes, um comando para voltar atrás.

### **roteiro (15 min)**

dry-run do setup de permissões

verify\_permissions.py

health\_report: ALL\_GRANTED

apply + backup automático

tarefa autônoma no agy

restore\_permissions.py --latest



# poc 2 · claudegravity

Vamos subir o gateway 9Router, conectar a conta Google AI Pro e validar a ponte de ponta a ponta.

## O QUE VAMOS FAZER

Claude Code rodando em Gemini 3.8 com 1M de contexto, sem gastar token de API.

## roteiro (15 min)

`docker compose up -d`

`test_gateway.py` → PONG

combo claudegravity-fallback

OAuth antigravity no dashboard

`claude --model ag/gemini-3.8-flash-high`

`keep_connected.py --daemon`



# poc 3 · resiliência

---

Vamos provocar falhas reais, 429 e logout, e provar que a sessão do Claude Code não cai.

## O QUE VAMOS FAZER

A cascata salta sozinha entre 5 provedores, e o Ollama local garante o piso.

## roteiro (15 min)

setup\_combos.py (5 provedores)

test\_arsenal.py nível a nível

simulate\_fallback.py (429/401)

salto de combo no dashboard

claude --model arsenal-supremo

ollama como última barreira

# path **ai**

---

A iniciativa Pathbit para o ecossistema de IA: conteúdos abertos, POCs reais e ferramentas que evoluem com a comunidade.

## PARA A COMUNIDADE

Esta sessão será gravada e publicada no YouTube da Pathbit, aberta a todos.

assista no [youtube](#) · [pathbit](#) · [pathbit-ai-for-devs](#)

## PATH AI

a iniciativa pathbit para o ecossistema de ia

conteúdos

pocs

ferramentas

gravação da sessão disponível no youtube



# referências & fontes

---

Conteúdos, ferramentas e fontes desta sessão, tudo aberto e clicável.

## ONDE SE APROFUNDAR

Todos os conteúdos da Pathbit estão no repositório, clona, roda e contribui.

## links & fontes

[pathbit-ai-for-devs](#) · [todo o conteúdo](#)

[antigravity.google](#) · [deepclaude](#)

[9router](#) · [code.claude.com/docs](#)

[openrouter.ai](#) · [groq.com](#) · [mistral.ai](#)

[ollama.com](#) · [ai.google.dev](#)

[swebench.com](#) · [arena.ai](#) · [designarena.ai](#)

Modelos vão e vêm,  
a arquitetura fica.

obrigado! os conteúdos estão no repositório, clona,  
roda e vamos conversar.

**#FaleComAPath**

(11) 5192-4633

[tecnologia@pathbit.com.br](mailto:tecnologia@pathbit.com.br)

[www.pathbit.com.br](http://www.pathbit.com.br)

# sua licença **gemini**

Para acompanhar as POCs e usar os modelos de fronteira no seu dia a dia, solicite sua licença Google AI Pro (Gemini + Antigravity).

## PASSO 1: CRIAR CONTA GOOGLE COM E-MAIL PATHBIT

<https://sites.google.com/pathbit.co/ajuda/google/criar-conta-google>

## PASSO 2: SOLICITAR LICENÇA GEMINI

Você deve logar em um navegador com sua conta @pathbit.co ou @pathbit.com.br

<https://forms.gle/P8JBjdGEvyuwcUZ57>

**a licença cobre Gemini 3.x,  
Antigravity IDE e a CLI agy**



<https://forms.gle/P8JBjdGEvyuwcUZ57>